






Aprendizaje por Refuerzo en IA



Beltrán Salazar Norberto Rafael



¿Qué es el Aprendizaje por Refuerzo?

Concepto clave · RL en IA

Paradigma de aprendizaje automático donde un agente aprende por ensayo y error interactuando con un entorno para **maximizar la recompensa acumulada**.

- **Prueba y error**

Paradigma de ML guiado por la experiencia directa del agente.

- **Basado en MDP**

Estados, acciones, recompensas y transiciones estocásticas.

- **Objetivo claro**

Maximizar la recompensa acumulada a lo largo del tiempo.

- **Explorar vs. explotar**

Equilibrio entre descubrir y aprovechar lo ya aprendido.

RL = agente + entorno + recompensa → aprende políticas óptimas mediante interacción.

RL vs. Supervisado y No Supervisado

Comparativa de paradigmas de ML

Aprendizaje Supervisado

Etiquetas disponibles ($X \rightarrow Y$)

- Predicción/clasificación con datos etiquetados
- Asume muestras i.i.d. por registro
- Optimiza pérdida de predicción (p. ej., MAE, cross-entropy)

Aprendizaje No Supervisado

Sin etiquetas; descubre estructura

- Agrupación, reducción de dimensión, estimación de densidad
- Criterios: cohesión/separación o reconstrucción
- No hay señal de recompensa ni política

Aprendizaje por Refuerzo (RL)

Recompensas; aprende a actuar

- Datos secuenciales estado-acción-recompensa (MDP)
- Exploración vs. explotación; aprende una **política** π
- Objetivo: maximizar recompensa acumulada a largo plazo

Componentes principales del RL

Diagrama Agente ↔ Entorno · Estado, Acción, Recompensa

Componentes

- Agente
- Entorno
- Estado (S)
- Acción (A)
- Recompensa (R)

Agente

Decide acciones

Entorno

Provee estados y recompensas

Objetivo del RL: aprender una política que maximice la recompensa acumulada a largo plazo.

Flujo: Agente → Acción → Entorno → [Estado, Recompensa] → Agente

Aplicaciones en el mundo real

Videojuegos · Robótica · Coches autónomos · Finanzas



Videojuegos

Agentes que superan niveles y compiten.

- Atari (aprendizaje a partir de píxeles)
- Dota 2 (juego en equipo a gran escala)



Robótica

Control inteligente en entornos cambiantes.

- Navegación
- Manipulación



Coches autónomos

Toma de decisiones y planificación de ruta.

- Conducción en simuladores
- Interacción segura con el entorno



Finanzas

Optimización de decisiones bajo incertidumbre.

- Trading algorítmico
- Gestión de carteras y riesgos

Caso de éxito: AlphaGo

Redes de política y valor + MCTS · Imitación + Autojuego

Hito histórico

4-1 vs Lee Sedol (2016)

Movimiento 78 (Juego 4)

Jugada creativa e inesperada que cambió el curso del partido.

Primera victoria de una IA sobre un campeón mundial de Go.

Sistema

Dos redes profundas: **política** (selección de jugadas) y **valor** (evaluación de posiciones).

Búsqueda con **Monte Carlo Tree Search (MCTS)** para planificar.

Entrenamiento

Imitación de partidas de expertos (aprendizaje supervisado inicial).

Autojuego con aprendizaje por refuerzo para mejorar iterativamente.

Legado

AlphaZero: dominio generalizado por *self-play* sin datos humanos.

MuZero: aprende un *modelo implícito* de la dinámica del juego.

Impacto: demostró que el RL + redes profundas pueden resolver dominios de gran complejidad estratégica.

Caso de éxito: OpenAI Five y otros

Dota 2 5v5 · PPO + redes recurrentes



OpenAI Five (Dota 2 5v5)

Entrenamiento a gran escala con PPO + redes recurrentes

Victorias vs.
profesionales

Escalabilidad

Miles de partidas simultáneas para explorar estrategias de equipo.

Política recurrente

RNN para memoria temporal y coordinación multi-agente.

Resultado: desempeño competitivo y demostraciones públicas contra equipos profesionales.



AlphaZero

Ajedrez, Go y Shogi mediante *self-play* sin datos humanos.



MuZero

Aprende un modelo implícito para planificar sin conocer la dinámica.



AlphaDev

Optimización de algoritmos de bajo nivel mediante búsqueda guiada por RL.

Ventajas y desafíos del RL

Aprendizaje sin etiquetas · Control secuencial



Ventajas

Fortalezas clave del aprendizaje por refuerzo

- **Aprende sin etiquetas**
Optimiza decisiones a partir de señales de recompensa.
- **Descubrimiento y creatividad**
Puede descubrir estrategias novedosas y eficaces.
- **Transferible a dominios diversos**
Aplicable en robótica, juegos, finanzas y más.



Desafíos

Retos prácticos y técnicos

- **Ineficiencia muestral**
Alto costo computacional y necesidad de muchas experiencias.
- **Estabilidad y seguridad**
Sensibilidad a hiperparámetros y diseño de recompensas.
- **Exploración vs. explotación**
Equilibrio difícil, especialmente en espacios grandes.
- **Sim2Real en robótica**
Brecha entre simulación y mundo real limita la transferencia.

Conclusiones y futuro del RL

Potencial · Direcciones de crecimiento

Resumen

El aprendizaje por refuerzo (RL) demuestra alto potencial para optimizar decisiones secuenciales sin etiquetas, descubrir estrategias creativas y transferir conocimiento a múltiples dominios.



RL basado en modelos

Aprender y planificar con modelos internos para mayor eficiencia muestral.



Offline RL

Aprender políticas a partir de datos históricos sin interacción directa.



Integración con LLMs y RLHF

Mejor alineación y capacidad de razonamiento con retroalimentación humana.



Mejores simuladores

Sim2Real más fiel para reducir la brecha entre simulación y mundo real.



Oportunidades: industria · salud · energía

Optimización de procesos, apoyo clínico y gestión de redes energéticas.



¡Gracias!

